

Практическая работа № 6.1

Библиотека NumPy для работы с данными

Задание 6.1. Библиотека NumPy.

6.1.1. Библиотека *NumPy*. Импорт библиотеки.

6.1.2. Массивы. Структура.

6.1.3. Создание массива. Функции *array()* - создание массива и *values()* - преобразование датафрейма в массив (пример 6.1.2).

6.1.4. Функции создания массива заданного вида.

6.1.5. Индексирование массивов NumPy. Индекс и срез.

Массив NumPy

Это мощный многомерный массив в форме строк и колонок. С помощью библиотеки можно создавать массивы NumPy из вложенного списка Python и получать доступ к его элементам.

Массив NumPy — это не то же самое, что и класс `array.array` из Стандартной библиотеки Python, который работает только с одномерными массивами.

Одномерный массив NumPy.

```
import numpy as np

a = np.array([1, 2, 3])
print(a)
```

Результатом кода выше будет [1 2 3].

Многомерные массивы.

```
import numpy as np

a = np.array([[1, 2, 3], [4, 5, 6]])
print(a)
```

Результат — [[1 2 3] [4 5 6]].

Атрибуты массива NumPy

ndarray.ndim

Возвращает количество измерений массива.

```
import numpy as np
a = np.array([[1, 2, 3], [4, 5, 6]])
print(a.ndim)
```

Вывод кода сверху будет 2, поскольку «a» — это 2-мерный массив.

ndarray.shape

Возвращает кортеж размера массива, то есть (n,m), где n — это количество строк, а m — количество колонок.

```
import numpy as np
a = np.array([[1, 2, 3], [4, 5, 6]])
print(a.shape)
```

Вывод кода — (2,3), то есть 2 строки и 3 колонки.

ndarray.size

Возвращает общее количество элементов в массиве.

```
import numpy as np
a = np.array([[1, 2, 3], [4, 5, 6]])
print(a.size)
```

Вывод — 6, потому что 2 x 3.

ndarray.dtype

Возвращает объект, описывающий тип элементов в массиве.

```
import numpy as np
a = np.array([[1, 2, 3], [4, 5, 6]])
print(a.dtype)
```

Вывод — «int32», поскольку это 32-битное целое число. Можно явно определить тип данных массива NumPy.

```
import numpy as np
a = np.array([[1, 2, 3], [4, 5, 6]], dtype = float)
print(a.dtype)
```

Этот код вернет float64, потому что это 64-битное число с плавающей точкой.

ndarray.itemsize

Возвращает размер каждого элемента в массиве в байтах.

```
import numpy as np
a = np.array([[1, 2, 3], [4, 5, 6]])
print(a.itemsize)
```

Вывод — 4, потому что $32/8$.

ndarray.data

Возвращает буфер с актуальными элементами массива. Это альтернативный способ получения доступа к элементам через их индексы.

```
import numpy as np
a = np.array([[1, 2, 3], [4, 5, 6]])
print(a.data)
```

Этот код вернет список элементов.

ndarray.sum()

Функция вернет сумму все элементов ndarray.

```
import numpy as np
a = np.random.random((2, 3))
print(a)
print(a.sum())
```

Сгенерированная в этом примере матрица — $\begin{bmatrix} 0.46541517 & 0.66668157 & 0.36277909 \\ 0.7115755 & 0.57306008 & 0.64267163 \end{bmatrix}$, следовательно код вернет 3.422183052180838. Поскольку используется генератор случайных чисел, ваш результат будет отличаться.

ndarray.min()

Функция вернет элемент с минимальным значением из ndarray.

```
import numpy as np
a = np.random.random((2, 3))
print(a.min())
```

Сгенерированная в этом примере матрица — $\begin{bmatrix} 0.46541517 & 0.66668157 & 0.36277909 \\ 0.7115755 & 0.57306008 & 0.64267163 \end{bmatrix}$, следовательно код вернет 0.36277909. Поскольку используется генератор случайных чисел, ваш результат будет отличаться.

ndarray.max()

Функция вернет элемент с максимальным значением из ndarray.

```
import numpy as np
a = np.random.random((2, 3))
print(a.min())
```

Сгенерированная в этом примере матрица — `[[0.46541517 0.66668157 0.36277909] [0.7115755 0.57306008 0.64267163]]`, следовательно код вернет `0.7115755`. Поскольку используется генератор случайных чисел, ваш результат будет отличаться

Функции NumPy

`type(numpy.ndarray)` Это функция Python, используемая, чтобы вернуть тип переданного параметра. В случае с массивом `numpy`, она вернет `numpy.ndarray`.

```
import numpy as np

a = np.array([[1, 2, 3], [4, 5, 6]])
print(type(a))
```

Код выше вернет `numpy.ndarray`.

`numpy.zeros()`

`numpy.zeros((rows, columns), dtype)`

Эта функция создаст массив `numpy` с заданным количеством измерений, где каждый элемент будет равняться 0. Если `dtype` не указан, по умолчанию будет использоваться `dtype`.

```
import numpy as np
np.zeros((3, 3))
print(a)
```

Код вернет массив `numpy` 3×3 , где каждый элемент равен 0.

`numpy.ones()`

`numpy.ones((rows, columns), dtype)`

Эта функция создаст массив `numpy` с заданным количеством измерений, где каждый элемент будет равняться 1. Если `dtype` не указан, по умолчанию будет использоваться `dtype`.

```
import numpy as np
np.ones((3, 3))
print(a)
```

Код вернет массив `numpy` 3×3 , где каждый элемент равен 1.

`numpy.empty()`

`numpy.empty((rows, columns))`

Эта функция создаст массив, содержимое которого будет случайным — оно зависит от состояния памяти.

```
import numpy as np
np.empty((3, 3))
```

```
print(a)
```

Код вернет массив numpy 3×3 , где каждый элемент будет случайным.

numpy.arange()

numpy.arange(start, stop, step)

Эта функция используется для создания массива numpy, элементы которого лежат в диапазоне значений от start до stop с разницей равной step.

```
import numpy as np
a=np.arange(5,25,4)
print(a)
```

Вывод этого кода — [5 9 13 17 21]

numpy.linspace()

numpy.linspace(start, stop, num_of_elements)

Эта функция создаст массив numpy, элементы которого лежат в диапазоне значений между start до stop, а num_of_elements — это размер массива. Тип по умолчанию — float64.

```
import numpy as np
a=np.linspace(5,25,5)
print(a)
```

Вывод — [5 10 15 20 25].

numpy.logspace()

numpy.logspace(start, stop, num_of_elements)

Эта функция используется для создания массива numpy, элементы которого лежат в диапазоне значений от start до stop, а num_of_elements — это размер массива. Тип по умолчанию — float64. Все элементы находятся в пределах логарифмической шкалы, то есть представляют собой логарифмы соответствующих элементов.

```
import numpy as np
a = np.logspace(5,25,5)
print(a)
```

Вывод — [1.e+05 1.e+10 1.e+15 1.e+20 1.e+25].

numpy.sin()

numpy.sin(numpy.ndarray)

Этот код вернет синус параметра.

```
import numpy as np
a = np.logspace(5,25,2)
print(np.sin(a))
```

Вывод кода сверху равен [0.0357488 -0.3052578]. Также есть cos(), tan() и так далее.

numpy.reshape()

numpy.reshape(dimensions)

Эта функция используется для изменения количества измерений массива numpy. От количества аргументов в reshape зависит, сколько измерений будет в массиве numpy.

```
import numpy as np
a = np.arange(9).reshape(3,3)
print(a)
```

Вывод этого кода — 2-мерный массив 3×3.

numpy.random.random()

numpy.random.random((rows, column))

Эта функция возвращает массив с заданным количеством измерений, где каждый элемент генерируется случайным образом.

```
a = np.random.random((2,2))
```

Этот код вернет ndarray 2×2.

numpy.exp()

numpy.exp(numpy.ndarray)

Функция вернет ndarray с экспоненциальной величиной каждого элемента.

```
b = np.exp([10])
```

Значением кода выше будет 22025.4657948.

numpy.sqrt()

numpy.sqrt(numpy.ndarray)

Эта функция вернет ndarray с квадратным корнем каждого элемента.

```
b = np.sqrt([16])
```

Этот код вернет значение 4.

Базовые операции NumPy

```
a = np.array([5, 10, 15, 20, 25])
```

```
b = np.array([0, 1, 2, 3])
```

Этот код вернет разницу двух массивов

```
c = a - b
```

Этот код вернет массив, где каждое значение возведено в квадрат
b**2

Этот код вернет значение в соответствии с заданным выражением

```
10 * np.sin(a)
```

Этот код вернет True для каждого элемента, чье значение удовлетворяет условию

```
a < 15
```

Базовые операции с массивом NumPy

```
a = np.array([[1,1], [0,1]])
```

```
b = np.array([[2,0], [3,4]])
```

Этот код вернет произведение элементов обоих массивов

```
a * b
```

Этот код вернет матричное произведение обоих массивов

```
a @ b
```

или

```
a.dot(b)
```

Пример 6.1.1

Создание массивов

```
import numpy as np
arr1 = np.array([1,2,3,4])
print('arr1 =',arr1)
arr2 = np.array([5,6,7,8], dtype = float)
print('arr2 =',arr2)
arr2.dtype

arr3 = np.array([[1,2,3], [4,5,6], [7,8,9]])
np.shape(arr3)      # размерность
```

Пример 6.1.2

Преобразовать датафрейм или его часть, содержащую количественные показатели, в объект ndarray

```
import numpy as np
import pandas as pd

df = pd.DataFrame()
x = df.values
type(x)
```

x, полученный таким образом из DataFrame практически представляет собой матрицу – массив с двумя индексами (номер строки и номер колонки, соответственно).

Используя функцию values, массив можно получить из **Series**:

```
import numpy as np
import pandas as pd
my_series = pd.Series([5, 6, 7, 8, 9, 10])
my_series.values
```

Пример 6.1.3

Массив заданного вида

`np.empty(5)` # одномерный массив из пяти элементов, память для которого выделена, но не инициализирована

`np.zeros((10, 7))` # массив размером 10x7, заполненный нулями

`np.ones((3,3,3))` # массив размером 3x3x3, заполненный единицами

`np.eye(3)` # единичная матрица (элементы главной диагонали равны 1, остальные — 0) размера 3x3

`np.full((3, 5), 3.14)` # массив 3x5 заполненный числом 3.14

`np.arange(0, 21, 7)` # одномерный массив, заполненный числами в диапазоне от 0 до 20 с шагом 7

`np.linspace(0, 1, 5)` # массив из пяти чисел, равномерно распределённых в интервале между 0 и 1 включительно

`np.random.randint(0, 10, (3, 3))` # массив размера 3x3, заполненный случайными числами из диапазона от 0 до 9 (включительно)

Пример 6.1.4

Индексация и срез

Основные правила:

- индекс **первого** элемента массива равен 0;

- для обращения к элементу массива по индексу необходимо указать **имя** переменной, в которой хранится массив, и **индекс** в квадратных скобках;

- допускается использование **отрицательных** индексов;

```
my_array = np.array([x for x in range(10)])
```

```
my_array[5]
```

```
my_array[-1]
```

```
my_array[3:6]
```

```
my_array[1:8:3]
```

```
my_array = np.array([[1, 2, 3, 4], [10, 11, 12, 13],
[45, 46, 47, 48]])
my_array[1][2]
```


`my_array[1, 2]`

Функции с массивами

Функция	Описание
<code>abs</code>	Абсолютное значение целых, вещественных или комплексных элементов массива
<code>sqrt</code>	Квадратный корень каждого элемента массива
<code>exp</code>	Экспонента (e^x) каждого элемента массива
<code>log</code> , <code>log10</code> , <code>log2</code> , <code>log1p</code>	Натуральный (по основанию e), десятичный, двоичный логарифм и функция $\log(1+x)$ соответственно
<code>modf</code>	Дробные и целые части массива в виде отдельных массивов
<code>isnan</code>	Массив логических (булевых) значений, показывающий, какие из элементов исходного массива являются NaN (не числами)
<code>cos</code> , <code>sin</code> , <code>tan</code>	Обычные тригонометрические функции
<code>arccos</code> , <code>arcsin</code> , <code>arctan</code>	Обратные тригонометрические функции

Создадим массив `students`

ID (номер в журнале)	Рост, см	Масса тела, кг	Средний балл
1	135	34	4
2	160	43	5
3	163	40	4.3
4	147	44	5
5	138	41	4.7

Вычисление среднего

```
mean = np.mean(students[:, -1])
```

Вычисление медианы

Многое в нахождении медианы зависит от того, **четное или нечетное количество наблюдений**.

Если n нечетное. Тут все просто: в середине окажется одно центральное значение.
$$k = \frac{n+1}{2} = 3$$
 медиана равна $x_3=34$ (следующий урок)

Если n четное. В середине оказывается два наблюдения. В таком случае мы находим среднее арифметическое этих двух значений.

k между $n/2$ и $n/2+1$

Узнаем, как учится средний ученик, с помощью **функции median**:

```
median = np.median(students[:, -1])
```

Вычисление **коэффициента корреляции** столбцов матрицы:

```
corr = np.corrcoef(students[:, 1], students[:, 2])
```